Aplicación de Representaciones Semánticas Modernas en el Sistema Extender

Rodrigo N. Herlein

July 3, 2026

Índice

1 Motivación **2**

2 Objetivo del proyecto **2**

3 Corpus utilizado **3**

4 Cómo funciona Extender y Pipeline de Trabajo **3**
4.1 Representación del mapa conceptual 4
4.2 Filtrado 4
4.2.1 Comparación con centroid y aspects 5
4.2.2 Comparación con *_map_vec* 5
4.3 Reducción de dimensionalidad (UMAP), Clustering (HDBSCAN) y selección de nivel 5
4.3.1 Formula de score para seleccionar un nivel 5
4.3.2 Quality 6
4.3.3 Focus 6
4.3.4 Specificity 7
4.4 c-TF-IDF 7
4.5 Ranking 7

5 Archivos del proyecto **8**

6 Parámetros de configuración **8**
6.1 Comparación de vectores con el corpus 9
6.2 Clustering 9
6.3 Selección de nivel del árbol 9
6.4 Filtros de categoría 9
6.5 Filtros 10
6.6 Infraestructura 10

7 Archivos del proyecto **10**

8 Caso de uso **10**

9 Trabajo a futuro **13**

10 Conclusiones **13**

1 Motivación

Este trabajo está basado en el paper *"Mining for Topics to Suggest Knowledge Model Extensions"* y la tesis de posgrado, *"Intelligent Support for Knowledge Capture and Construction"*. Ambos trabajos plantean un mismo problema: un experto que quiere representar visualmente su conocimiento sobre un tema a través de un mapa conceptual. El objetivo de Extender es ayudar a capturar y extender los conocimientos del experto mientras trabaja en el mapa conceptual, recomendando nuevos tópicos relacionados con lo que el experto ya había capturado en el mismo.

La implementación original de Extender resolvía esto con herramientas basadas en frecuencia: funciones de term-weighting (descriptive, discriminative, focus, exhaustivity), frecuencia de términos, y un algoritmo de co-clustering. Estas técnicas funcionan, pero tienen diversos problemas como limitaciones en la comprension semántica, dificultad para incorporar información conceptual o secuencial, vocabulario limitado, entre otras. Si el mapa dice "sample return" y el documento dice "returning samples from Mars", una técnica basada en frecuencia de términos no necesariamente conecta ambos.

Este proyecto busca cambiar las estrategias basadas en frecuencia de terminos por métodos en embeddings: usar embeddings de oraciones (generados con SBERT) para que la comparación entre el mapa conceptual y los documentos del corpus se haga en un espacio vectorial donde el significado importa más que la coincidencia exacta de palabras. E identificar tematicas latentes en un corpus de gran tamaño utilizando el pipeline de BERTopic

2 Objetivo del proyecto

El objetivo del proyecto es adaptar el algoritmo de recomendación de tópicos de Extender, reemplazando las técnicas basadas en frecuencia (term-weighting, co-clustering) por métodos basados en embeddings (SBERT, UMAP, HDBSCAN).

Esto implica, entre otras cosas:

- Representar el mapa conceptual del experto como uno o más embeddings en el mismo espacio semántico que el corpus.
- Reemplazar la recuperación de documentos por frecuencia de términos por una recuperación basada en similitud por coseno entre embeddings.
- Reemplazar el algoritmo de co-clustering (documento, término) por clustering jerárquico sobre embeddings (HDBSCAN).
- Mantener la misma idea que la implementación original: dado un contexto inicial, descubrir y recomendar tópicos relacionados pero haciendo la búsqueda sobre un corpus local en lugar de consultas a la web.

Es importante aclarar que al iniciar el proyecto de plantearon objetivos como:

- Reemplazar las herramientas basadas en frecuencia utilizadas dentro del algoritmo de extender por herramientas basadas en embeddings.
- Analizar el desempeño del algoritmo con métricas adecuadas.
- Analizar la factibilidad de comparar los resultados de las métricas obtenidas con los resultados obtenidos para el algoritmo original de extender.

Estos objetivos debieron ser modificados debido a la amplitud del proyecto y quedan como parte del trabajo futuro.

3 Corpus utilizado

El corpus utilizado es el directorio **Curlie**, compuesto por archivos TSV en pares:

- `rdf-{Tag}-c.tsv`: contenido — URL, título, descripción e ID de cada página web.
- `rdf-{Tag}-s.tsv`: estructura — ID, ruta de categoría dentro del directorio Curlie, cantidad de entradas y descripción de la categoría.

El `Tag` puede ser global (*Arts*, *Business*, *Top*, *Society*, *World*, *Adult*) o regional (*Deutsch*, *Français*, *Italiano*, *Japanese*, entre otros).

El texto embeddeado de cada entrada es la concatenación de los campos título, descripción, ruta de categoría (con `"/"` y `"_"` reemplazados por espacios para que parezca una oración normal como las que entiende SBERT).

Se tienen más de **260,000 embeddings**, cada una representada por un vector SBERT de 384 dimensiones. Estos embeddings son almacenados en una archivo externo para no tener que volver a calcularlos en cada ejecución. Las tareas de almacenamiento y busqueda dentro de la caché fueron implementadas por claude code, ya que no formaban parte del interes principal de este proyecto a lo largo del cuatrimestre.

4 Cómo funciona Extender y Pipeline de Trabajo

Extender es un sistema que captura y extiende el conocimiento de un experto: dado un contexto inicial (un mapa conceptual), busca descubrir y recomendar tópicos relacionados con ese contexto. En la versión original esto se hacía a través de consultas en la web; en esta versión se hace sobre un corpus local (Curlie).

El pipeline del proyecto tiene las siguientes etapas, todas operando en el mismo espacio vectorial de 384 dimensiones generado por el modelo actual de SBERT utilizado:

- **Representación (con SBERT,** `all-MiniLM-L6-v2`**)**: Genera distintas representaciones para el mapa conceptual.
- **Generación de embeddings del corpus (con SBERT,** `all-MiniLM-L6-v2`**)**: Genera un embedding por cada documento presente en el corpus como se menciono en la sección 3.
- **Filtrado**: filtrado por fuerza bruta usando similitud por coseno.
- **Reducción de dimensionalidad (UMAP)**: preserva la estructura local del espacio reduciendo de 384 a 10 dimensiones.
- **Clustering (HDBSCAN)**: clustering jerárquico sobre el espacio reducido. Cada cluster representa un tópico relacionado al mapa conceptual.
- **c-TF-IDF**: obtiene las palabras más representativas de cada cluster.
- **Ranking**:arma el ranking final de tópicos.

Se usa el mismo modelo SBERT en cada punto del pipeline para mantener consistencia: todos esos vectores tienen que vivir en el mismo espacio de 384 dimensiones para que las comparaciones por similitud por coseno tengan sentido. Si se usaran modelos distintos para partes distintas del pipeline, los vectores resultantes no serían comparables entre sí.

Las estrategias planteadas a lo largo de esta sección fueron elegidas mediante prueba y error. Aunque el objetivo inicial era elegir cada metodología mediante el analisis de fuentes academicas, el tiempo disponible no permitió una investigación en detalle del estado del arte (la cual queda

pendiente como trabajo a futuro) y se decidió utilizar las estrategias que brindaran mejores resultados luego de las pruebas planteadas.

4.1 Representación del mapa conceptual

Primero veamos como se calcula el peso topologico de un nodo en el mapa conceptual. Para ello se utiliza la siguiente formula:

$$w(v) = 0.5 \cdot \text{deg_score}(v) + 0.5 \cdot \text{dist_score}(v) \tag{1}$$

Siendo $deg_score(v)$ y $dist_score(v)$ implementadas de la siguiente manera:

$$\text{deg_score}(v) = \frac{\text{cant_edge}(v)}{\max_edge()} \tag{2}$$

$$\text{dist_score}(v) = 1 - \frac{\text{dist}(v)}{\max_dist + 1} \tag{3}$$

El mapa conceptual se representa mediante tres tipos de vectores, todos construidos a partir de los embeddings SBERT de las etiquetas de sus conceptos.

- **Centroide**: Es el promedio ponderado de los embeddings de todos los conceptos del mapa. El peso de cada concepto es su peso topológico (calculado con la formula (1)), multiplicado por 3 si el concepto pertenece al conjunto de *focus concepts* (un grupo especial de onceptos determinado por el usuario al iniciar el sistema extender).
- **Aspect vectors**: el centroide solo captura el "promedio" del mapa y puede perder zonas periféricas. Por eso se generan hasta 4 aspect vectors en total (incluyendo el centroide). Primero se ordenan los conceptos por peso topológico, y para cada uno se calcula el promedio del vector con los vectores de los conceptos que se encuentran en su "vecindario" (el concepto más sus hasta 4 vecinos directos, promediados). Si ese vector es demasiado similar a algún aspect ya agregado (similitud por coseno > 0.97), se descarta. Se para al llegar a 4 aspects. Tanto la cantidad de aspect vectors como el umbral de similitud por coseno pueden configurarse dentro del código y son valores a ajustar en el trabajo futuro.
- `_map_vec`: a diferencia del centroide y los aspects (que promedian embeddings de los conceptos sin contexto), el vector `_map_vec` se construye a partir de una oración armada al concatenar todos los conceptos del mapa. Esto le da a SBERT contexto para resolver ambigüedades. En el mapa de Marte, la oración "rovers sample return mars space missions landing surface" le indica a SBERT que "return" es retorno de muestras y no, retorno de una inversión (por dar un ejemplo).

4.2 Filtrado

El filtrado tiene dos etapas

- **Comparación con centroid y aspects**
- **Comparación con** $_map_vec$

4.2.1 Comparación con centroid y aspects

Para cada uno de los 4 aspect vectors:

1. Se calcula la similitud por cosena de ese aspecto con todos los embeddings del corpus.
2. Se toma el top 500 de los más similares (la constante 500 es configurable al iniciar el sistema)
3. Sobre los 500 elementos seleccionados, se aplican dos filtros.
   (a) La similitud por coseno entre el elemento y el aspect debe ser mayor o igual a 0.15 (umbral configurable)
   (b) La similitud por coseno entre el elemento y el centroide del mapa conceptual (aspect 0) debe ser mayor o igual a 0.10 (umbral configurable)

Los filtros por umbral pretenden establecer un piso minimo de similitud para cada documento.

4.2.2 Comparación con *_map_vec*

Sobre los documentos que pasaron el filtro con los aspects:

1. Se calcula la similitud por coseno entre cada documento y el *_map_vec*
2. Similitud por coseno entre el elemento y el *_map_vec* debe ser mayor o igual a 0.10 (umbral configurable)
3. Al menos 30 documentos deben pasar el umbral, de lo contrario se topa el top 30 de los más similares para generar los clusters necesarios (umbral configurable)

Las estrategias de filtrado son arbitrarias y se definieron luego de un procesod e prueba y error con otras estrategias. Las mismas están sujetas a posibles cambios en el futuro.

4.3 Reducción de dimensionalidad (UMAP), Clustering (HDBSCAN) y selección de nivel

UMAP reduce las dimensiones de los embeddings de los candidatos de 384 a 10 dimensiones, y sobre ese espacio reducido corre HDBSCAN (con `cluster_selection_method="eom"`). HDBSCAN construye una jerarquía completa de clusters variando el umbral de densidad y extrae los clusters más persistentes; los puntos que no caen en ningún cluster quedan como outliers (tópico -1).

4.3.1 Formula de score para seleccionar un nivel

Para seleccionar el nivel de la jerarquía generada con HDBSCAN se recorre el árbol para poder cortarlo a cualquier altura. Para cada corte candidato (se define un grupo de niveles con parametros configurables) se calculan tres métricas *focus* (similitud promedio ponderada entre los centroides del tópico contra el mapa), *specificity* (inverso del coeficiente Gini de los tamaños, para penalizar cortes desequilibrados) y *quality* (fracción de tópicos que pasarían 5 filtros aplicados con parámetros configurables: coherencia, foco, tamaño, dominio y exclusión) y se combinan en un score ponderado. Se elige el nivel con score total más alto.

La formula para realizar el corte es la siguiente (las constantes son parámetros configurables):

$$score = 0.45 \cdot focus + 0.35 \cdot specificity + 0.20 \cdot quality \tag{4}$$

4.3.2 Quality

Para calcular **Quality** en un determinado nivel del arbol, en cada cluster se evaluan los siguientes umbrales:

- **Coherencia** del cluster debe ser mayor o igual a 0.20: significando que el cluster internamente es suficientemente compacto
  - La coherencia se calcula armando un centroide del cluster y comparando ese centroide mediante similitud por coseno con todos los documentos del cluster. Al finalizar se realiza un promedio de todas las similitudes calculadas dando como resultado la coherencia del cluster.
- **Focus** del cluster debe ser mayor o igual a 0.05: significando que el centroide del cluster está lo suficientemente cerca del mapa conceptual
  - El focus se calcula armando un centroide del cluster y comparando ese centroide mediante similitud por coseno con $_map_vec$.
- El **tamaño** del cluster debe ser menor o igual a $(0.35 * \text{numero de candidatos})$: implicando que no es un cluster residual gigante.
- El **dominio** del cluster debe ser mayor o igual 0.4: implicando que al menos un 40% de los documentos del cluster tienen relación con palabras clave configuradas por el usuario.
  - El usuario tiene la posibilidad de especificar strings importantes en la configuración, esos strings deben ser especificados con criterio ya que deben estar relacionados con el mapa conceptual
  - El dominio entonces se calcula analizando la categoría que propone curlie para cada documento del cluster. Luego de controlar todos los documentos se calcula:

$$frac_dom = \frac{\text{cant_documentos_con_palabras_clave_en_su_categoria_en_el_cluster}}{\text{cant_documentos_del_cluster}} \tag{5}$$

- La **exclusion** del cluster debe ser menor o igual 0.3: implicando que hay menos de un 30% de documentos en el cluster que tienen palabras clave configuradas por el usuario para ser rechazadas.
  - El usuario tiene la posibilidad de especificar strings a ser rechazados en la configuración, esos strings deben ser especificados con criterio.
  - La exclusion entonces se calcula analizando la categoría que propone curlie para cada documento del cluster. Luego de controlar todos los documentos se calcula:

$$frac_dom = \frac{\text{cant_documentos_con_palabras_excluidas_en_su_categoria_en_el_cluster}}{\text{cant_documentos_del_cluster}} \tag{6}$$

El valor final de quality para un nivel se calcula según la siguiente formula:

$$frac_dom = \frac{\text{cant_documentos_que_superaron_los_filtros_de_calidad}}{\text{cant_documentos_del_cluster}} \tag{7}$$

4.3.3 Focus

Para calcular **Focus** de un determinado nivel, previamente se calculó el foco de cada cluster por lo que se usan esos resultados en la siguiente formula:

$$\text{focus} = \frac{\sum_{i=1}^{n} \text{focus_cluster}_i \cdot \text{size}_i}{\sum_{i=1}^{n} \text{size}_i} \tag{8}$$

Donde n es la cantidad de grupos en ese nivel, focus_cluster_i es la similitud por coseno del centroide del grupo i contra _map_vec, y size_i es la cantidad de documentos del grupo i.

4.3.4 Specificity

Para calcular **specificity** de un determinado nivel, calculamos el coeficiente de Gini con la siguiente formula:

$$\text{Gini} = \frac{2\sum_{i=1}^{n} i \cdot s_{(i)}}{n\sum_{i=1}^{n} s_{(i)}} - \frac{n+1}{n} \tag{9}$$

Donde S_i son los tamaños de los n clusters ordenados por tamaño de manera ascendente e i es el ranking de cada tamaño.

La espeficidad se calcula invirtiendo el coeficiente de Gini, ya que no buscamos medir desigualdad, sino similitud.

$$\text{specificity} = 1 - \text{Gini} \tag{10}$$

Si la cantidad de clusters es 1 o 0, se le asigna 0 a specificity.

4.4 c-TF-IDF

Con el objetivo de identificar cada cluster con un conjunto de palabras clave, se realiza lo siguiente:

1. Se crea una matriz TF con todos los documentos que forman parte del armado de clusters.
2. Luego se calcula la matriz IDF con esos documentos y terminos.
3. Para cada cluster
   (a) toman solo los documentos pertenecientes al mismo en la matris IDF
   (b) Se calcula un promedio de las apariciones de cada termino en los distintos documentos
   (c) Se toman los 10 terminos con mayor promedio para representar al cluster.

Luego esos 10 terminos representan al cluster y los primeros 3 se usan como título del mismo.

4.5 Ranking

Como paso final se realiza un ranking de los clusters obtenidos con la finalidad de mostrarle al usuario los mismos en orden de relevancia para el tema de trabajo. No todos los clusters podrán entrar al ranking, solo aquellos que cumplan con los filtros finales se mostraran al usuario.

Es importante aclarar que el ranking fue el area a la cual se le dedicó menos tiempo y por lo tanto, la más sujeta a subjetividades. **En el trabajo futuro, esta parte del pipeline debe ser revisada integramente**.

Los pasos finales para ubicarse en el ranking son:

1. **Filtrado final** Se evalúan nuevamente los siguientes filtros y cualquier grupo que no los verifique, no aparece en el ranking.

- **Coherencia** >= 0.20.
- **Focus** >= 0.05.
- **tamaño** <= (0.35 ∗ numero de candidatos):
- **exclusion** <= 0.30:

2. **Overlap** El overlap es la sumatoria de los pesos topologicos de las keywords del tópico obtenidas con c-TF-IDF pero solo para aquellas que también sean terminos del mapa conceptual. Captura que parte del vocabulario del mapa también aparece en las keywords del tópico y que tan relevante es esa palabra en el mapa conceptual.

$$\text{overlap}(t) = \sum w(keyword) \tag{11}$$

3. **Score final** Por último se toma el valor de focus y de coherencia y se calcula el score con la siguiente formula:

$$\text{score}(t) = \text{overlap}(t) \times \big(0.4 + 0.3 \cdot \text{coherencia} + 0.3 \cdot \text{focus}\big) \tag{12}$$

   - Si ninguna keyword aparece en el mapa conceptual entonces el overlap se vuelve 0 al igual que el score. Se da un piso de 0.4 para el score en caso de que coherencia y focus fueran 0. Todas las constantes de la formula son configurables.

4. **Penalización** Una vez calculado el score, si el porcentaje de documentos que contienen palabras del dominio aclarado en la configuración no supera el umbral de 0.4 entonces se multiplica el score de ese tópico por 0.05 para bajar su posición en el ranking.
5. **Orden final** Según el score, se devuelven 6 tópicos en orden descendiente o menos en caso de que no haya suficientes tópicos que hayan cumplico con los filtros finales.

5 Archivos del proyecto

Archivo	Rol
`curlie_corpus.py`	Carga el corpus de Curlie teniendo en cuenta los filtros de categoría deseados.
`extender_bertopic.py`	Arma el mapa conceptual y realiza las operaciones necesarias para trabajar con él; también contiene la implementación clásica de Extender (búsqueda web iterativa).
`concept_map_encoder.py`	Genera los vectores (centroide, aspects) que representan al mapa conceptual.
`topic_explorer.py`	Controla el pipeline nuevo del proyecto de punta a punta, desde la representación hasta el ranking final de tópicos.
`run_collab.ipynb`	Notebook que busca los archivos en Drive y ejecuta el proyecto, definiendo los parámetros de `ExplorerConfig` para cada corrida.

6 Parámetros de configuración

Todos los hiperparámetros por defecto del pipeline están presentes en la clase `ExplorerConfig` pero pueden cambiarse creando un objeto de tipo ExplorerConfig y enviandolo al constructor de

la clase TopicExplorer, la cual controla el pipeline de ejecución. A continuación se listan todos los hiperparámetros agrupados por etapa.

6.1 Comparación de vectores con el corpus

- `top_k_per_aspect` (default 500): cantidad de documentos tomados al evaluar cada aspect vector contra el corpus.
- `min_aspect_sim` (default 0.15): umbral mínimo de similitud por coseno contra el aspect correspondiente.
- `min_doc_relevance` (default 0.10): umbral mínimo de similitud por coseno contra `_map_vec`.

6.2 Clustering

- `min_cluster_size` (default 5): cantidad mínima de documentos para formar un cluster en HDBSCAN.
- `min_samples` (default 2): densidad mínima; por debajo de este umbral los puntos se consideran ruido.
- `umap_n_components` (default 10): dimensiones a las que UMAP reduce el espacio de 384 dimensiones.
- `umap_n_neighbors` (default 20): cantidad de vecinos considerados por UMAP al armar el grafo de vecindad.

6.3 Selección de nivel del árbol

Los tres pesos siguientes deben sumar 1:

- `focus_weight` (default 0.45 o 0.3 en las pruebas): peso de la similitud promedio ponderada de los centroides de tópico con el mapa.
- `specificity_weight` (default 0.35 / 0.50): peso del inverso del coeficiente Gini de los tamaños de los tópicos; penaliza que un solo tópico absorba todo el candidate set.
- `quality_weight` (default 0.20): peso de la fracción de tópicos del corte que pasarían todos los filtros de salida.
- `min_nr_topics` / `max_nr_topics` (default 4 / 15): rango de cortes del árbol jerárquico que se evalúan.

6.4 Filtros de categoría

- `domain_category_keywords`: strings que deben aparecer en la categoría Curlie del documento para considerarlo parte del dominio (por ejemplo, para el mapa de la Luna: "Science", "Astronomy", "Lunar", "Moon", "Apollo", "NASA", etc.). Si un tópico no cumple una fracción mínima de documentos en el dominio, recibe una penalización en el ranking.
- `domain_category_min_fraction` (default 0.40): fracción mínima de documentos en categorías de dominio.
- `domain_category_penalty` (default 0.05): factor de penalización si no se alcanza el mínimo anterior.
- `exclude_category_keywords`: categorías puestas a mano para ser descartadas a la fuerza (por ejemplo, para el mapa de la luna de la tierra: `Earth_Sciences/Paleontology`,

`Earth_Sciences/Natural_Disasters`, entre otras). Se agregó porque hay documentos que parecen tener una cercanía semántica pero que no tienen relación real con el tema del mapa.

- `exclude_category_max_fraction` (default 0.30): si más de esta fracción de los documentos de un tópico cae en categorías de exclusión, el tópico se descarta por completo.

6.5 Filtros

- `min_coherence` (default 0.20): similitud por coseno promedio mínima entre los documentos de un cluster y su propio centroide. Por debajo de este valor, el cluster es ruido de HDBSCAN sin un tema claro.
- `min_output_focus` (default 0.05): similitud por coseno mínima entre el centroide del tópico y `_map_vec`. Es un valor bajo adrede, pensado como piso.
- `max_topic_fraction` (default 0.35): si un tópico contiene más de este porcentaje de los documentos candidatos, se descarta por ser un cluster residual de HDBSCAN (durante las pruebas se observó un cluster "space/science/technology" con más del 35% de los candidatos y este parámetro permitió sacarlo del ranking).
- `n_output_topics` (default 6): cantidad final de tópicos retornados en el ranking.

6.6 Infraestructura

- `cache_dir`: directorio donde se guarda el `.npz` con los embeddings del corpus.
- `random_state` (default 42): semilla usada por UMAP y HDBSCAN.
- `SBERT all-MiniLM-L6-v2`: Modelo de SBERT utilizado. Fue el primero en dar resultados y es posible que cambie a futuro.

7 Archivos del proyecto

Archivo	Rol
`curlie_corpus.py`	Carga el corpus de Curlie.
`extender_bertopic.py`	Arma el mapa conceptual y contiene las operaciones necesarias para manipularlo; también contiene la implementación previa de Extender (con búsqueda web iterativa).
`concept_map_encoder.py`	Genera los vectores (centroide, aspects) que representan al mapa conceptual.
`topic_explorer.py`	Controla el pipeline del proyecto, desde la representación hasta el ranking final de tópicos.
`run_collab.ipynb`	Notebook que busca los archivos en Drive y ejecuta el proyecto, definiendo los parámetros de `ExplorerConfig` para cada prueba.

8 Caso de uso

Se presenta una prueba de Extender a modo de ejemplo. Dado el siguiente mapa conceptual:

Los Tópicos sugeridos fueron los siguientes:

- Tópico 1: mars_missions_space

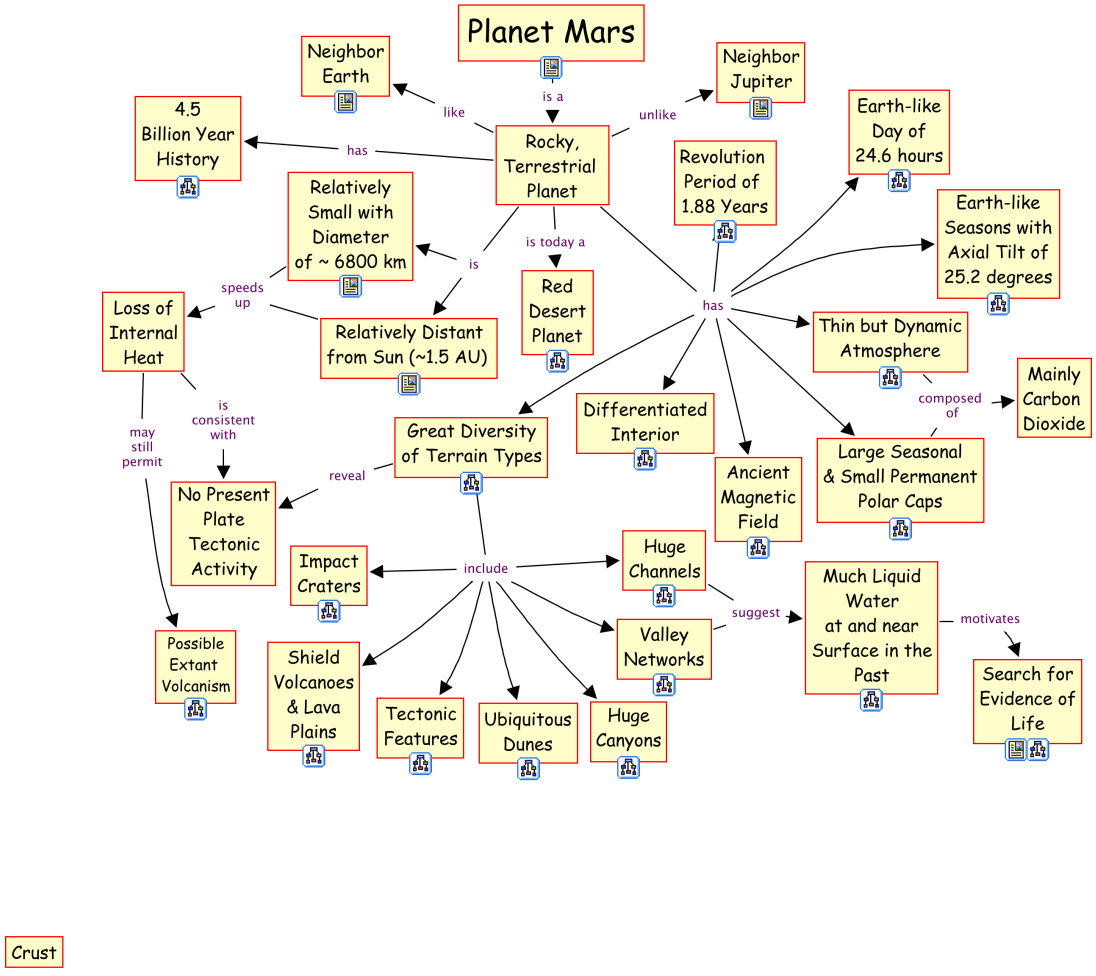


Figure 1: Mapa conceptual de Marte usado como caso de prueba.

  - Keywords : mars, missions, space, space missions, mission, unmanned, missions unmanned, technology space
  - Coherencia : 0.656 Focus: 0.675 Docs: 151

- Tópico 2: space_robotics_technology
  - Keywords : space, robotics, technology, science technology, science, computers, computers robotics, technology space
  - Coherencia : 0.524 Focus: 0.530 Docs: 317

- Tópico 3: science_astronomy_united
  - Keywords : science, astronomy, united, europe, kingdom, united kingdom, amateur, science astronomy
  - Coherencia : 0.534 Focus: 0.464 Docs: 261

- Tópico 4: services_products_surveying
  - Keywords : services, products, surveying, land, earth, computers, sciences, earth sciences
  - Coherencia : 0.526 Focus: 0.479 Docs: 449

En mayor detalle, los tópicos son los siguientes:

- Tópico 1: mars_missions_space
  - Keywords : mars, missions, space, space missions, mission, unmanned, missions unmanned, technology space
  - Coherencia : 0.656 Focus: 0.675 Docs: 151
  - Ejemplos:
    - **NASA - Mars Reconnaissance Orbiter**
      Includes a mission overview, spacecraft views, current status, and highlights.
      [Science/Technology/Space/Missions/Unmanned/Mars/Mars_Re]
      http://www.nasa.gov/mission_pages/MRO/main/index.html
    - **Mars Pathfinder Mission**
      Mission information and selected Rover images.
      [Science/Technology/Space/Missions/Unmanned/Mars/Mars_Pa]
      http://www.solarviews.com/eng/pathfind.htm
- Tópico 2: space_robotics_technology
  - Keywords : space, robotics, technology, science technology, science, computers, computers robotics, technology space
  - Coherencia : 0.524 Focus: 0.530 Docs: 317
  - Ejemplos:
    - **NASA Robotics Education Project**
      Contains information about NASA's Robotics Education Project, including applications for NASA grants and a special program.
      [Computers/Robotics/Competitions/FIRST_Robotics_Competit]
      http://robots.nasa.gov/
    - **Space Science**
      Links to images and current news stories. Overview of scientific missions.
      [Science/Technology/Space/NASA]
      http://spacescience.nasa.gov/
- Tópico 3: science_astronomy_united
  - Keywords : science, astronomy, united, europe, kingdom, united kingdom, amateur, science astronomy
  - Coherencia : 0.534 Focus: 0.464 Docs: 261
  - Ejemplos:
    - **South West Herts Astronomical Society**
      Meetings, events, special course, images, and observation log books.
      [Regional/Europe/United_Kingdom/England/Hertfordshire/Sc]
      http://swhas.org/
    - **Deep Sky Exploration**
      News, history, activities, library, newsletter, and organization.
      [Science/Astronomy/Amateur/Organizations/Europe]
      http://www.dse.no/
- Tópico 4: services_products_surveying

  - Keywords : services, products, surveying, land, earth, computers, sciences, earth sciences
  - Coherencia : 0.526 Focus: 0.479 Docs: 449
  - Ejemplos:
    * **Terraquest Ltd**
      Specializes in airborne geophysical surveys, geophysical consulting, data interpretation, enhancement and modeling.
      [Science/Earth_Sciences/Geophysics/Products_and_Services]
      http://www.terraquest.ca/
    * **Met Surveys**
      Offers land and building surveys using laser technology, geophysical services, archaeological investigations.
      [Science/Earth_Sciences/Geomatics/Land_Surveying/Surveyo]
      http://www.metsurveys.com/

Los resultados completos pueden accederse en el archivo results_mars_explorer

9 Trabajo a futuro

- Estudiar métricas relevantes para evaluar el desempeño de Extender.
- Buscar un corpus alternativo, más adecuado para los contextos iniciales disponibles, y correr pruebas comparativas con el corpus Curlie actual.
- Hacer fine-tuning de SBERT sobre un corpus de dominio específico y analizar los resultados obtenidos frente al uso del modelo sin fine tuning.
- Explorar alternativas para representar el mapa conceptual con embeddings, más allá del esquema actual de centroide + aspects.
- Explorar alternativas para el ranking de tópicos y documentos que se le muestra al usuario final.
- Mejorar los hiperparámetros del pipeline mediante pruebas exhaustivas (grid search o similar), en particular los pesos de `focus_weight` / `specificity_weight` / `quality_weight`.
- Analizar en detalle el rendimiento de HDBSCAN con métodos de evaluación intrínseca.
- Migrar el modelo SBERT actual (`all-MiniLM-L6-v2`) a uno más reciente, como `all-MiniLM-L12-v2`, o a uno de mayor dimensionalidad como `all-mpnet-base-v2`.
- Evaluar la posibilidad de agregar o eliminar filtros para simplificar el pipeline propuesto.
- Evaluar la opción de generar un aspect vector por concepto en mapas chicos o que la cantidad de aspect vectors crezca con el mapa.
- Y más...

10 Conclusiones

El sistema Extender ya comienza a mostrar resultados, aunque aún queda mucho trabajo por hacer para que los resultados complan con las expectativas iniciales.

Los objetivos planteados inicialmente para el proyecto quedaron relegados a trabajo a futuro debido a la amplitud del proyecto pero los resultados obtenidos hasta el momento son prometedores

El objetivo de adaptar Extender a tecnologías basadas en embeddings se cumplió: el reemplazo de term-weighting y co-clustering por BERTopic (SBERT + UMAP + HDBSCAN) está funcionando sobre el corpus Curlie. Nuevamente, todavía queda trabajo por delante para que el sistema funcione de la manera esperada en todos los casos. En particular, la calibración de umbrales y pesos sigue apoyándose en valores razonables (obtenidos luego de pruebas empíricas) más que en una búsqueda exhaustiva o investigación academica, y hay preguntas abiertas que ameritan un análisis más profundo.

Mi objetivo personal en este cuatrimestre fue aprender lo más posible y buscar como aplicarlo en el area donde yo trabajo. El objetivo se cumplió y termino el cuatrimestre más que contento, con la idea de que voy a continuar trabajando en temas que me gustan y la sensación de que aún no encontré todos los temas que me gustan, lo cual me deja muy ilusionado. Gracias Ana.